



Рубежный контроль №1

Тенишев Александр ИУ5-65Б

Вариант 18

Задача 3

Набор данных, указанного в задачах 2 https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html#sklearn.datasets.load_wine

```
In [63]: from sklearn.datasets import load_wine
import pandas as pd
```

```
In [64]: df = load_wine()
data = pd.DataFrame(df.data, columns=df.feature_names)
```

```
In [65]: # размер набора данных
data.shape
```

```
Out[65]: (178, 13)
```

```
In [66]: # типы колонок
data.dtypes
```

```
Out[66]: alcohol                float64
malic_acid                    float64
ash                          float64
alcalinity_of_ash            float64
magnesium                    float64
total_phenols                float64
flavanoids                   float64
nonflavanoid_phenols        float64
proanthocyanins              float64
color_intensity              float64
hue                          float64
od280/od315_of_diluted_wines float64
proline                      float64
dtype: object
```

```
In [67]: # Первые 5 строк датасета
data.head()
```

```
Out[67]:
```

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavan
0	14.23	1.71	2.43		15.6	127.0	2.80
1	13.20	1.78	2.14		11.2	100.0	2.65
2	13.16	2.36	2.67		18.6	101.0	2.80
3	14.37	1.95	2.50		16.8	113.0	3.85
4	13.24	2.59	2.87		21.0	118.0	2.80

```
In [68]: data.isnull().sum()
```

```
Out[68]: alcohol                0
malic_acid                    0
ash                          0
alcalinity_of_ash             0
magnesium                    0
total_phenols                0
flavanoids                   0
nonflavanoid_phenols         0
proanthocyanins              0
color_intensity              0
hue                          0
od280/od315_of_diluted_wines 0
proline                      0
dtype: int64
```

ЗАДАЧА 3

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

```
In [69]: from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler()

data['proline_scaled'] = scaler.fit_transform(data[['proline']])
```

```
In [70]: data.head()
```

Out[70]:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavan
0	14.23	1.71	2.43	15.6	127.0	2.80	
1	13.20	1.78	2.14	11.2	100.0	2.65	
2	13.16	2.36	2.67	18.6	101.0	2.80	
3	14.37	1.95	2.50	16.8	113.0	3.85	
4	13.24	2.59	2.87	21.0	118.0	2.80	

Создание искусственного категориального признака (требуется по заданию).
Разделим содержание алкоголя на три категории:

```
In [71]: data['alcohol_category'] = pd.cut(
        data['alcohol'],
        bins=3,
        labels=['low', 'medium', 'high']
    )

print(data[['alcohol', 'alcohol_category']].head(100))
```

```
   alcohol alcohol_category
0    14.23             high
1    13.20            medium
2    13.16            medium
3    14.37             high
4    13.24            medium
..     ...             ...
95   12.47            medium
96   11.81             low
97   12.29             low
98   12.37            medium
99   12.29             low
```

[100 rows x 2 columns]

```
In [72]: from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()

data['alcohol_label'] = le.fit_transform(data['alcohol_category'])

print(data[['alcohol_category', 'alcohol_label']].head(100))
```

	alcohol_category	alcohol_label
0	high	0
1	medium	2
2	medium	2
3	high	0
4	medium	2
..	...	...
95	medium	2
96	low	1
97	low	1
98	medium	2
99	low	1

[100 rows x 2 columns]

In [73]: `print(type(data))`

<class 'pandas.DataFrame'>

In [74]: `from sklearn.preprocessing import OneHotEncoder
encoder = OneHotEncoder(sparse_output=False)

encoded = encoder.fit_transform(data[['alcohol_category']])

encoded_data = pd.DataFrame(
 encoded,
 columns=encoder.get_feature_names_out(['alcohol_category']),
 index=data.index
)

data = pd.concat([data, encoded_data], axis=1)

print(data.filter(like='alcohol_category').head(100))`

	alcohol_category	alcohol_category_high	alcohol_category_low	\
0	high	1.0	0.0	
1	medium	0.0	0.0	
2	medium	0.0	0.0	
3	high	1.0	0.0	
4	medium	0.0	0.0	
..	...	...	...	
95	medium	0.0	0.0	
96	low	0.0	1.0	
97	low	0.0	1.0	
98	medium	0.0	0.0	
99	low	0.0	1.0	

	alcohol_category_medium
0	0.0
1	1.0
2	1.0
3	0.0
4	1.0
..	...
95	1.0
96	0.0
97	0.0
98	1.0
99	0.0


[100 rows x 4 columns]

Для студентов группы ИУ5-65Б, ИУ5-66Б, ИУ5И-61Б - для набора данных построить "парные диаграммы".

```
In [78]: import seaborn as sns
import matplotlib.pyplot as plt
data['target'] = load_wine().target
```

```
In [79]: cols = ['alcohol', 'malic_acid', 'color_intensity', 'proline', 'ash']

sns.pairplot(data[cols + ['target']], hue='target')
plt.show()
```



Масштабирование признака — MinMaxScaler

Приводит значения признака proline к диапазону [0, 1].

Почему использовали:

- признаки в датасете имеют разные масштабы

например:

- alcohol $\approx$ 10-15
- proline $\approx$ сотни/тысячи

без масштабирования модели могут “перекосяться” в сторону больших чисел

Label Encoding

Преобразует категории:

- low $\rightarrow$ 0
- medium $\rightarrow$ 1
- high $\rightarrow$ 2

Почему использовали:

- нужно получить числовое представление категорий
- удобно для моделей, которые работают с числами напрямую

Ограничение:

Label encoding вводит искусственный порядок, которого может не быть

One-Hot Encoding

Создаёт отдельные бинарные признаки:

- low $\rightarrow$ [1,0,0]
- medium $\rightarrow$ [0,1,0]
- high $\rightarrow$ [0,0,1]

Почему использовали:

- чтобы убрать ложный порядок между категориями
- делает категории независимыми
- улучшает качество моделей, чувствительных к расстояниям и линейности